

面向大模型输出长度预测的理论实验框架： 从事前规划到事后修正

2026 年 7 月 9 日

1 数学理论建模

整个框架的核心在于**贝叶斯序列推断 (Bayesian Sequential Inference)**。我们通过事前规划提取长尾先验分布 (Prior)，在解码过程中通过事后修正引入观测证据 (Evidence) 以持续更新后验分布 (Posterior)，从而实现对输出长度的动态逼近。

1.1 事前规划 (Pre-planning): 基于几何映射的长尾先验建模

在预填充 (Prefill) 阶段结束时 ($t = 0$)，我们提取大模型中间层 (如 Layer 14) 最后一个 Token 的隐藏状态 $h_0 \in \mathbb{R}^d$ ，以此建立对全局输出长度的初始先验分布。

几何映射投影 隐状态 h_0 在潜空间流形上表征了当前生成任务的语义重心。线性探针本质上是在该流形上寻找一个一维投影轴 W_μ ，其投影标量代表预期生成长度的对数均值：

$$\mu_0 = W_\mu^T h_0 + b_\mu \quad (1)$$

长尾先验分布 (Log-Normal Prior) 考虑到复杂任务 (如代码生成、逻辑推理) 在输出时的高度不确定性与高方差特性，生成总长度 L 倾向于服从重尾分布。设定其服从对数正态分布，概率密度函数 (PDF) 为：

$$P(L | h_0) = \frac{1}{L\sigma_0\sqrt{2\pi}} \exp\left(-\frac{(\ln L - \mu_0)^2}{2\sigma_0^2}\right) \quad (2)$$

其中 σ_0^2 表示该指令的固有认知不确定性 (Aleatoric Uncertainty)，可通过回归残差提前拟合。

1.2 事后修正 (Post-correction): 基于熵衰减的停时后验更新

进入解码 (Decode) 阶段 ($t > 0$)，模型每生成一步，都会产生新的隐藏状态 h_t 与局部信息熵 $E_t = -\sum p_i \log p_i$ 。

熵衰减动力学 (Entropy Dynamics) 随着语义上下文逐渐完备，序列的平均信息熵往往呈现指数或线性衰减趋势。我们定义瞬时生成速率（即触发 End-of-Sequence, EOS 的强度） λ_t 为：

$$\lambda_t = f(E_t, h_t) \approx \exp(-\alpha E_t + \beta t) \quad (3)$$

剩余长度的停时分布 定义剩余待生成长度 $R_t = L - t$ 。在观测到前 t 步的熵轨迹 $E_{1:t}$ 后，剩余长度 R_t 服从依赖于当前状态的停时分布：

$$P(R_t = r \mid h_t, E_{1:t}) \propto \lambda_{t+r} \exp\left(-\int_0^r \lambda_{t+\tau} d\tau\right) \quad (4)$$

动态期望修正 在第 t 步时，系统获取的最新动态长度全局估计值为：

$$\hat{L}_t = t + \mathbb{E}[R_t \mid h_t, E_{1:t}] \quad (5)$$

随着生成步数 t 的推进，剩余长度的方差 $\text{Var}(R_t)$ 将快速收敛至 0。

2 实验设计

2.1 第一环：离线分布拟合与先验验证 (Offline Profiling)

- **实验目标：**验证生成长度 L 服从长尾分布的理论假设，并证明对数均值 μ_0 与隐状态 h_0 在潜空间中高度线性相关。
- **执行步骤：**基于 Qwen-2.5-7B 运行规模化的多样性指令集；利用前向传播钩子（Forward Hook）提取预填充阶段中间层的 h_0 ，同时记录真实的最终长度 L 与生成过程中的熵轨迹 E_t 。
- **评估指标：**使用最大似然估计（MLE）拟合对数正态分布。绘制理论 PDF 曲线与真实长度直方图的残差分析图，并计算探针回归的决定系数 R^2 与平均绝对误差（MAE）。

2.2 第二环：动态修正机制的微观验证 (Micro-benchmark)

- **实验目标：**证明事后修正模块能够捕捉局部信息熵的衰减，从而快速降低剩余长度的预测方差 $\text{Var}(R_t)$ 。
- **执行步骤：**冻结 LLM 权重，构建并训练一个以静态先验 T_0 、当前步数 t 、当前信息熵 E_t 以及局部滑动熵平均值 $\bar{E}_{t-k:t}$ 为输入的轻量级 MLP 修正模块。设定观测步长阈值（如每生成 5 个 Token 触发一次网络推理）。
- **评估指标：**绘制“不确定性锥形图（Cone of Uncertainty）”。以解码步数 t 为横坐标，预测区间为纵坐标，观察 95% 置信区间如何随着上下文的增长而收敛并逼近真实长度曲线。

2.3 第三环：端到端预测性能基准测试 (End-to-End Benchmark)

- **实验目标：**在完整的推理生命周期中，全面对比“事前规划 + 事后修正”混合框架与纯静态、纯动态基线方案的综合预测性能。

- **执行步骤**: 构建对比实验组, 包含: (1) 基于输入长度特征的传统基线; (2) 纯静态的 ALPS 中间层探针; (3) 纯动态的 PLP 渐进式预测; (4) 本文提出的混合预测框架。在不同温度参数 (Temperature) 和不同任务类型 (问答、摘要、代码) 下进行推理打分。
- **评估指标**: 统计全局 MAE、均方根误差 (RMSE), 以及达到目标预测精度 (如误差 $\leq 5\%$) 所需的平均 Token 步数 (评估收敛速度)。

2.4 第四环: 误差溯源与理论反哺 (Error Analysis & Theory Refinement)

- **实验目标**: 通过分析预测失效的长尾 Case (Outliers), 反向修正信息熵衰减动力学模型。
- **执行步骤**: 提取第三环测试中预测误差畸高 (如绝对误差 > 100 tokens) 的样本。分析失效原因: 是由于模型产生了内部“幻觉” (表现为 E_t 异常反弹或高频震荡), 还是由于指令本身具有开放式涌现性质。
- **评估指标**: 基于异常样本的特征, 调整动力学方程 $\lambda_t = f(E_t, h_t)$ 中的非线性项系数, 优化软标签 (Soft Label) 交叉熵损失函数的权重分配, 完成理论与实验的最终闭环。