

ALPS v1 诊断与 ALPS v2 服务器操作手册

面向 Qwen2.5-7B-Instruct 长度预测实验的逐步执行、验收与回传指南

本手册的边界

先完成 ALPS v1 Train-only grouped-CV、基线比较、学习曲线和结果封存。在诊断结论明确之前，不采集 ALPS v2，不重新打开 v1 Test，也不进入 PLP。

阶段	是否需要 GPU	当前动作
代码检查	否	更新代码、运行 pytest 和 Ruff
v1 诊断	否	读取现有 432 条 Train trace
v1 封存	否	生成 checksums 与只读状态记录
v2 数据采集	是	仅在学习曲线确认增加数据有效后执行
v2 最终测试	是	全部配置冻结后只执行一次

版本：2026-07-29

1. 实验原则与目录约定

ALPS v1 的 108 条 Test rollout 已经被查看，因此它们只能作为历史最终结果。Ridge alpha、PCA、特征层、baseline 和概率校准均只能使用 Train grouped-CV 或未来独立 Calibration split 选择。

禁止事项

不得根据 v1 Test 修改 alpha 后再次报告同一 Test；不得把同一 family 的 Short、Medium、Long 或不同 seed 分散到训练折和验证折；不得用 v1 Test 残差校准 v2 概率区间。

服务器项目根目录

```
cd /data/home/mulei/Summer_Camp
```

关键路径

路径	用途
data/interim/alps_v1/train/	432 条冻结训练 trace
artifacts/runs/alps_v1/diagnostics/	grouped-CV 与学习曲线
artifacts/runs/alps_v1/archive/	封存元数据与 checksum
configs/experiments/alps_v2_manifest.template.json	v2 规划模板，当前不可直接运行
docs/alps_v2_server_steps.md	与本 PDF 对应的命令清单

冻结模型条件

字段	值
Model	Qwen/Qwen2.5-7B-Instruct
Revision	a09a35458c702b33eeacc393d103063234e8bc28
Target	log1p(output_tokens)
Feature	zero-based Layer 14, last prompt token
Generation	BF16, temperature 0.7, top-p 0.95, max 4096

2. 更新代码并检查环境

从远端取得本次诊断工具。若正在使用 PR 分支，把分支名替换为 PR 中显示的名称。

```
cd /data/home/mulei/Summer_Camp
git status --short
git fetch origin
git switch agent/alps-v2-diagnostics
git pull --ff-only
```

工作区非空时

如果 git status 显示服务器上有未提交改动，先保存或提交它们，不要使用 git reset --hard，也不要覆盖未知文件。

非 Docker 服务器

```
python --version
python -m pip install --requirement requirements-autodl.lock
python -m pip install --no-deps --editable .
python -m pytest -q
ruff check --no-cache .
```

Docker 服务器

```
docker compose run --rm alps pytest
docker compose run --rm alps ruff check --no-cache .
```

验收标准

- pytest 全部通过；warning 可以记录，但不得存在 failed 或 error。
- Ruff 输出 All checks passed。
- 当前 Git commit SHA 被记录到日志或实验元数据中。

```
mkdir -p artifacts/runs/alps_v1/logs
git rev-parse HEAD | tee artifacts/runs/alps_v1/logs/diagnostic_commit.txt
```

3. 检查 ALPS v1 Train trace

grouped-CV 只使用 Train trace，不会读取 v1 Test。先检查数量：

```
find data/interim/alps_v1/train -name 'seed_*.jsonl' | wc -l
```

预期结果

必须为 432。不是 432 时停止，不要用不完整数据计算学习曲线。

可选完整性检查

```
find data/interim/alps_v1/train -name 'seed_*.jsonl' -size 0 -print
du -sh data/interim/alps_v1/train
df -h /data
```

检查内容

- 144 个独立 Train Prompt，每个 Prompt 对应 seeds 42、43、44。
- 模型与 tokenizer revision 均为冻结 SHA。
- 每条 trace 包含 Layer 14 hidden state、output_tokens 和 prompt_tokens。
- 所有 trace 的 split metadata 必须为 train。

为什么 432 不等于 432 个独立特征

同一个 Prompt 的三个 seed 使用相同的 prefill hidden state。三个 seed 主要用于估计生成随机性；对于静态均值模型，有效独立输入更接近 144 个 Prompt。因此交叉验证必须以 prompt_family_id 为组。

4. 运行 Family-grouped CV

```
set -o pipefail

python scripts/evaluate_grouped_cv.py \
  2>&1 | tee artifacts/runs/alps_v1/logs/grouped_cv.log
```

Docker 形式

```
set -o pipefail

docker compose run --rm -T alps \
  python scripts/evaluate_grouped_cv.py \
  2>&1 | tee artifacts/runs/alps_v1/logs/grouped_cv.log
```

默认比较模型

模型	特征	用途
global_mean	无	最低参照
prompt_tokens	输入 token 数	检查输入长度信号
metadata	任务 + 长度条件	检查组别信息是否已足够
metadata_prompt_tokens	metadata + 输入长度	最重要简单基线
alps_hidden	Layer 14 hidden state	ALPS 核心模型

默认 alpha

```
0.01 0.1 1 10 100 1000
```

输出文件

```
artifacts/runs/alps_v1/diagnostics/grouped_cv/results.json
artifacts/runs/alps_v1/diagnostics/grouped_cv/summary.csv
```

5. 读取 grouped-CV 结果并选择 alpha

首先查看摘要：

```
python - <<'PY'
import pandas as pd
p = 'artifacts/runs/alps_v1/diagnostics/grouped_cv/summary.csv'
df = pd.read_csv(p)
cols = ['model', 'alpha', 'prompt_mean_rmse_log1p',
        'prompt_mean_mae_tokens', 'prompt_mean_r_squared_log1p',
        'rollout_interval_95_coverage']
print(df[cols].sort_values('prompt_mean_rmse_log1p').to_string(index=False))
PY
```

没有 pandas 时
直接用 less 或电子表格打开 summary.csv；诊断脚本本身不依赖 pandas。

选择规则

- 主指标：Prompt-mean OOF RMSE on log1p scale，越低越好。
- 次指标：Prompt-mean token MAE，越低越好。
- 同时检查 OOF Log R²、coverage 和区间宽度。
- 差异很小时选择更强正则、更简单的配置。
- ALPS 必须与 metadata_prompt_tokens 在同一 fold 上比较。

Gate A：ALPS 特征是否有增量价值

结果	判断	下一步
ALPS 明显优于 metadata_prompt_tokens	隐藏状态有增量信息	运行学习曲线
二者接近	ALPS 增益不确定	先扩展 Prompt 多样性或降维
ALPS 更差	高维过拟合或特征不足	暂缓大规模 v2 采集

6. 运行学习曲线

把 `SELECTED_ALPHA` 替换为 Train grouped-CV 选出的 `alpha` :

```
set -o pipefail

python scripts/plot_learning_curve.py \
  --alpha SELECTED_ALPHA \
  2>&1 | tee artifacts/runs/alps_v1/logs/learning_curve.log
```

Docker 形式

```
set -o pipefail

docker compose run --rm -T alps \
  python scripts/plot_learning_curve.py --alpha SELECTED_ALPHA \
  2>&1 | tee artifacts/runs/alps_v1/logs/learning_curve.log
```

输出文件

```
artifacts/runs/alps_v1/diagnostics/learning_curve/results.json
artifacts/runs/alps_v1/diagnostics/learning_curve/learning_curve.csv
```

Gate B : 是否需要增加 Train Prompt

曲线形态	结论	建议
25% 到 100% 持续下降	增加独立 Prompt 很可能有效	先扩到 450 Train Prompts
75% 到 100% 已趋平	样本数不是唯一瓶颈	优先 PCA、特征或任务设计
波动大且无趋势	数据异质或样本过少	检查 family 平衡和近重复
Train 很好但 OOF 始终差	高维过拟合	加强正则和降维

算力分配原则

均值预测阶段，更多独立 Prompt 通常比更多 seed 更重要。Train v2 先用一个 seed ; Calibration 与 Test 再使用三个 seed 估计随机性。

7. 封存 ALPS v1

```
python scripts/archive_alps_v1.py

sha256sum --check \
  artifacts/runs/alps_v1/archive/checksums.sha256
```

必须产生

```
artifacts/runs/alps_v1/archive/archive_metadata.json
artifacts/runs/alps_v1/archive/checksums.sha256
```

封存检查

- archive_metadata.json 中 experiment_status 为 final_test_opened_read_only。
- 记录 Git commit SHA、Python 版本、GPU 信息和文件数量。
- checksums.sha256 校验全部通过。
- v1 Test 文件不再用于任何 v2 超参数选择。

打包并回传诊断结果

```
tar -czf alps_v1_diagnostics.tar.gz \
  artifacts/runs/alps_v1/diagnostics \
  artifacts/runs/alps_v1/archive \
  artifacts/runs/alps_v1/logs/grouped_cv.log \
  artifacts/runs/alps_v1/logs/learning_curve.log \
  artifacts/runs/alps_v1/logs/diagnostic_commit.txt

sha256sum alps_v1_diagnostics.tar.gz
```


8. ALPS v2 : 只有通过 Gate 后才执行

开始条件

只有当 Train grouped-CV 显示 ALPS 相比 metadata_prompt_tokens 有稳定增益，且学习曲线仍随数据量改善时，才批准生成更多 Prompt 并运行新 GPU 采集。

第一轮建议规模

Split	Families	Prompts	Seeds	Rollouts
Train	150	450	1	450
Calibration	30	90	3	270
Final Test	60	180	3	540
合计	240	720	-	1,260

v2 数据准备顺序

- 生成语义独立的 family，覆盖 QA、Summarization、Code。
- 每个 family 内建立 Short、Medium、Long，但整个 family 只能属于一个 split。
- 执行完全去重、标准化哈希去重和语义近重复检查。
- 冻结 prompt manifest 后填写 SHA-256，再把模板状态改成 runnable。
- 先采集 Train；模型选择完成后才采集 Calibration；最后只打开一次 Test。

v2 训练与校准候选

- Raw Layer 14 + Ridge。
- PCA 64 / 128 / 256 + Ridge。
- 全局 OOF log variance、长度分桶方差或 split conformal。
- 95% coverage 目标为 90%-98%，同时报告平均区间宽度。

10. 最终验收表

检查项	通过标准	状态
代码版本	服务器 commit SHA 已记录	☐
单元测试	pytest 无失败	☐
静态检查	Ruff All checks passed	☐
Train trace	恰好 432 条	☐
防泄漏	family-grouped CV	☐
基线	四类 baseline 均有结果	☐
alpha	仅基于 Train OOF 选择	☐
学习曲线	25/50/75/100%，每档 5 次	☐
v1 封存	checksum 全部通过	☐
v2 决策	根据 Gate A/B 明确记录	☐
Test 纪律	未重新使用 v1 Test 调参	☐

本轮完成定义

服务器返回完整 diagnostics 压缩包后，本轮诊断完成。随后才能决定：扩充到 450 个 Train Prompt、先做 PCA/正则化，或暂缓 ALPS v2。